

Les SVMs contre le Deep Learning

Clément DECHESNE



Atelier machine learning

12 mars 2019



Plan

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

- ➊ SVM
- ➋ Marge
- ➌ SVM linéaire
- ➍ Erreurs potentielles
- ➎ Cross-validation
- ➏ SVM non linéaire
- ➐ SVM vs Deep Learning
 - Datasets
 - Réseau
 - Un peu de code...
 - Résultats

SVM

Marge

SVM
linéaire


Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Objectif : Trouver une séparation linéaire entre deux ensembles



SVM

Marge

SVM
linéaire


Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Objectif : Trouver une séparation linéaire entre deux ensembles



$$D(x) = \text{sign}(f(x))$$

$$= \text{sign}(\mathbf{v}^T \mathbf{x} + a)$$

SVM

Marge

SVM
linéaire


Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Objectif : Trouver une séparation linéaire entre deux ensembles



$$\begin{aligned} D(\mathbf{x}) &= \text{sign}(f(\mathbf{x})) \\ &= \text{sign}(\mathbf{v}^T \mathbf{x} + \alpha) \end{aligned}$$


Une ligne de décision :
 $\mathbf{v}^T \mathbf{x} + \alpha = 0$

SVM

Marge

SVM
linéaireErreurs
potentiellesCross-
validationSVM non
linéaireSVM vs
Deep
Learning

Objectif : Trouver une séparation linéaire entre deux ensembles



$$\begin{aligned} D(\mathbf{x}) &= \text{sign}(f(\mathbf{x})) \\ &= \text{sign}(\mathbf{v}^T \mathbf{x} + \alpha) \end{aligned}$$

Une ligne de décision :
 $\mathbf{v}^T \mathbf{x} + \alpha = 0$

Mais il en existe beaucoup
d'autres

Le problème est **mal posé**

Comment trouver la meilleure solution ?

SVM

Marge

SVM
linéaire

Erreurs
potentielles


Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Le problème est un peu différent

Soit un ensemble d'apprentissage : $\{\mathbf{x}_i, y_i\}_{i \in [1, n]}$




On veut être capable de
classifier des observations
nouvelles en minimisant les
erreurs.

SVM

Marge

SVM
linéaireErreurs
potentiellesCross-
validationSVM non
linéaireSVM vs
Deep
Learning

Le problème est un peu différent

Soit un ensemble d'apprentissage : $\{\mathbf{x}_i, y_i\}_{i \in [1, n]}$ 

On veut être capable de classer des observations nouvelles en minimisant les **erreurs**.

$$D(\mathbf{x}) = \text{sign}(\mathbf{v}^T \mathbf{x} + a)$$

Comment trouver la meilleure solution ?
 \Rightarrow **maximiser la marge**
Vapnik (1982)

La marge d'un SVM

Maximiser la confiance = Maximiser la marge

La frontière de décision qui maximise la marge est :

$$\Delta(\mathbf{v}, \mathbf{a}) = \{\mathbf{x} \in \mathbb{R}^d | \mathbf{v}^T \mathbf{x} + \mathbf{a} = 0\}$$

$$\max_{\mathbf{v}, \mathbf{a}} \min_{i \in [1, n]} \underbrace{\text{dist}(\mathbf{x}_i, \Delta(\mathbf{v}, \mathbf{a}))}_{\text{marge: } m}$$

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

La marge d'un SVM

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Maximiser la confiance = Maximiser la marge

La frontière de décision qui maximise la marge est :

$$\Delta(\mathbf{v}, \mathbf{a}) = \{\mathbf{x} \in \mathbb{R}^d | \mathbf{v}^T \mathbf{x} + \mathbf{a} = 0\}$$

$$\max_{\mathbf{v}, \mathbf{a}} \underbrace{\min_{i \in [1, n]} \text{dist}(\mathbf{x}_i, \Delta(\mathbf{v}, \mathbf{a}))}_{\text{marge: } m}$$

Maximiser la marge

$$\begin{cases} \max_{\mathbf{v}, \mathbf{a}} m \\ \text{avec } \min_{i \in [1, n]} \frac{|\mathbf{v}^T \mathbf{x}_i + \mathbf{a}|}{\|\mathbf{v}\|} \geq m \end{cases}$$

La marge d'un SVM

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Maximiser la confiance = Maximiser la marge

La frontière de décision qui maximise la marge est :

$$\Delta(\mathbf{v}, \mathbf{a}) = \{\mathbf{x} \in \mathbb{R}^d | \mathbf{v}^T \mathbf{x} + \mathbf{a} = 0\}$$

$$\max_{\mathbf{v}, \mathbf{a}} \underbrace{\min_{i \in [1, n]} \text{dist}(\mathbf{x}_i, \Delta(\mathbf{v}, \mathbf{a}))}_{\text{marge: } m}$$

Maximiser la marge

$$\begin{cases} \max_{\mathbf{v}, \mathbf{a}} m \\ \text{avec } \min_{i \in [1, n]} \frac{|\mathbf{v}^T \mathbf{x}_i + \mathbf{a}|}{\|\mathbf{v}\|} \geq m \end{cases}$$

Problème encore mal posé :

si (\mathbf{v}, \mathbf{a}) est une solution, alors $\forall k > 0 (k\mathbf{v}, k\mathbf{a})$ est aussi solution

La marge d'un classifieur : marge numérique et marge géométrique

SVM

Marge


SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning



La marge d'un SVM

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Maximiser la marge :

$$\left\{ \begin{array}{l} \max_{\mathbf{v}, \alpha} m \\ \text{avec } \min_{i \in [1, n]} |\mathbf{v}^T \mathbf{x}_i + \alpha| \geq m \\ \|\mathbf{v}\|^2 = 1 \end{array} \right.$$

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Maximiser la marge :

$$\begin{cases} \max_{\mathbf{v}, \alpha} m \\ \text{avec } \min_{i \in [1, n]} |\mathbf{v}^T \mathbf{x}_i + \alpha| \geq m \\ \|\mathbf{v}\|^2 = 1 \end{cases}$$

Si le minimum est supérieur à la marge, alors tous les $|\mathbf{v}^T \mathbf{x}_i + \alpha|$ sont supérieur à la marge et $y_i \in \{-1, 1\}$

$$\begin{cases} \max_{\mathbf{v}, \alpha} m \\ \text{avec } y_i (\mathbf{v}^T \mathbf{x}_i + \alpha) \geq m \quad \forall i \in [1, n] \\ \|\mathbf{v}\|^2 = 1 \end{cases}$$

La marge d'un SVM

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

$$\begin{cases} \max_{\mathbf{v}, \alpha} m \\ \text{avec } y_i(\mathbf{v}^T \mathbf{x}_i + \alpha) \geq m \quad \forall i \in [1, n] \\ \|\mathbf{v}\|^2 = 1 \end{cases}$$

On effectue le changement de variable $\mathbf{w} = \frac{\mathbf{v}}{m}$ et $b = \frac{\alpha}{m}$

$$\Rightarrow \|\mathbf{w}\| = \frac{\|\mathbf{v}\|}{m}$$

La marge d'un SVM

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

$$\begin{cases} \max_{\mathbf{v}, a} m \\ \text{avec } y_i(\mathbf{v}^T \mathbf{x}_i + a) \geq m \quad \forall i \in [1, n] \\ \|\mathbf{v}\|^2 = 1 \end{cases}$$

On effectue le changement de variable $\mathbf{w} = \frac{\mathbf{v}}{m}$ et $b = \frac{a}{m}$

$$\Rightarrow \|\mathbf{w}\| = \frac{\|\mathbf{v}\|}{m}$$

$$\begin{cases} \max_{\mathbf{w}, b} m \\ \text{avec } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \forall i \in [1, n] \\ m = \frac{1}{\|\mathbf{w}\|} \end{cases}$$

$$\begin{cases} \min_{\mathbf{w}, b} \|\mathbf{w}\|^2 \\ \text{avec } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \forall i \in [1, n] \end{cases}$$

Définition SVM linéaire

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Définition : Soit $\{(\mathbf{x}_i, y_i); i \in [1, n]\}$ un ensemble de vecteur formes étiquetés avec $\mathbf{x}_i \in \mathbb{R}^d$ et $y_i \in \{-1, 1\}$. Un séparateur à vaste marge linéaire (SVM) est un discriminateur linéaire de la forme : $D(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x} + \mathbf{b})$ où $\mathbf{w} \in \mathbb{R}^d$ et $\mathbf{b} \in \mathbb{R}$ sont donnés par la résolution du problème suivant :

$$\begin{cases} \min_{\mathbf{w}, \mathbf{b}} \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{avec } y_i(\mathbf{w}^T \mathbf{x}_i + \mathbf{b}) \geq 1 \quad \forall i \in [1, n] \end{cases}$$

Erreurs potentielles

SVM

Marge


SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning



SVM

Marge


SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning



Idée : Modéliser les erreurs potentielles

$$(\mathbf{x}_i, y_i) \begin{cases} \text{pas d'erreur : } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \implies \xi_i = 0 \\ \text{erreur : } \xi_i = 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0 \end{cases}$$

Erreurs potentielles

SVM

Marge


SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning



Nouveau problème à résoudre :

$$\begin{cases} \min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{C}{p} \sum_{i=1}^n \xi_i^p & p = 1 \text{ ou } 2 \\ \text{avec } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i & \forall i \in [1, n] \\ \xi_i \geq 0 \end{cases}$$

Erreurs potentielles

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Le terme d'équilibrage $C > 0$ permet de fixer le coût d'une erreur :

Si C est **fort**, on tolère peu d'erreurs, la marge est plus faible

⇒ **moins bonne généralisation**

Si C est **faible**, on tolère beaucoup d'erreurs, la marge est plus grande

⇒ **meilleure généralisation**

Trouver un **bon** C est crucial.

Une méthode possible : la **cross-validation**

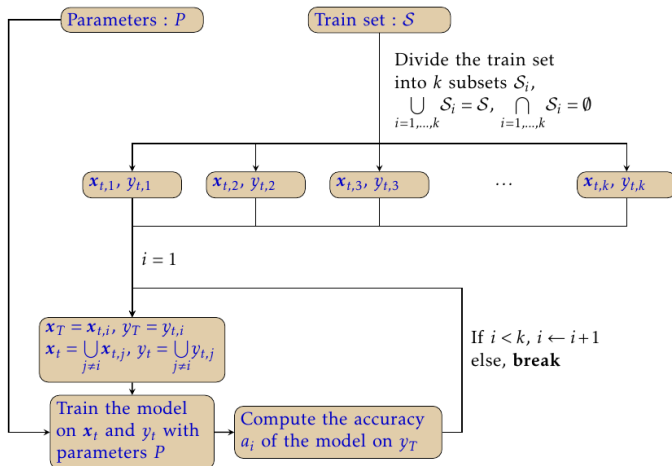
Cross-validation

SVM
Marge
SVM
linéaire
Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning



The accuracy for parameters P is $A = \frac{1}{k} \sum_{i=1}^k a_i$. The optimal set of parameters are chosen with regard to the greatest accuracy A .

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Dans la plupart des cas, la frontière optimale n'est pas linéaire. Dans le cadre des SVM, la prise en compte de non linéarités dans le modèle s'effectue par l'introduction de noyaux non linéaires. Ce noyau est une fonction K qui associe à tout couple d'observations $(\mathbf{x}_i, \mathbf{x}_j)$ une mesure de leur « influence réciproque » calculée à travers leur corrélation ou leur distance ; $K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{h}(\mathbf{x}_i))^T \mathbf{h}(\mathbf{x}_j)$.

Noyaux non linéaires

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Des exemples typiques de noyaux sont :

le noyau polynomial : $K(\mathbf{x}_i, \mathbf{x}_j) = (\langle \mathbf{x}_i, \mathbf{x}_j \rangle + 1)^d$,

le noyau gaussien : $K(\mathbf{x}_i, \mathbf{x}_j) = e^{-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2}$.

Dans l'espace des attributs transformés, $\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{h}(\mathbf{x}_i)$.

Donc $f(\mathbf{x}) = \mathbf{w}^T \mathbf{h}(\mathbf{x}) + b = \sum_{i=1}^n \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b$



Plan

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats

⑦ SVM vs Deep Learning

- Datasets
- Réseau
- Un peu de code...
- Résultats

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats

Utilisation de données synthétiques a 2 attributs (nuage de points) :

- + Contrôle du nombre d'échantillons
- + Interprétation visuelle
- Données "simple"
- Intérêt limité

Dataset - linéaire

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire



SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats



Dataset - circulaire

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire



SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats



SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire



SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats





Réseau employé

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats

Réseau simple (tâche peu complexe)

- 4 couches denses ayant le même nombre d'unités cachées
- activation ReLu



Code

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats

Les SVM sous python :

Module SVC de sklearn :

Créer un objet SVM :

Entraîner un SVM :

Score du SVM :

```
from sklearn.svm import SVC
clf = SVC(kernel="linear", C=c)
clf = SVC(kernel="rbf", C=c, gamma=g)
clf.fit(X, y)
clf.score(X, y)
```



Code

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats

Les SVM sous python :

Module SVC de sklearn :

Créer un objet SVM :

Entraîner un SVM :

Score du SVM :

```
from sklearn.svm import SVC
clf = SVC(kernel="linear", C=c)
clf = SVC(kernel="rbf", C=c, gamma=g)
clf.fit(X, y)
clf.score(X, y)
```

La cross validation :

Module KFold de sklearn :

Créer un ensemble :

Parcourir l'ensemble :

```
from sklearn.model_selection import KFold
kf = KFold(n_splits=N)
for train_index, test_index in kf.split(X):
```


Résultats - SVM - 50 échantillons

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire


SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats



Résultats - DL - 50 échantillons

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire


SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats



Résultats - SVM - 2000 échantillons

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire


SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats



Résultats - DL - 2000 échantillons

SVM

Marge

SVM
linéaire

Erreurs
potentielles

Cross-
validation

SVM non
linéaire

SVM vs
Deep
Learning

Datasets

Réseau

Un peu de
code...

Résultats

